




O PROBLEMA DO DESEQUILÍBRIO DE CLASSES

TRABALHO PRÁTICO –
APRENDIZAGEM COMPUTACIONAL I


Grupo 5: Afonso Marcos, Artur Anselmo,
Marcos Torres

O PROBLEMA DOS DADOS DESEQUILIBRADOS

Ponto de Situação: Com 1000 análises médicas em que apenas 30 são positivas. Um algoritmo que prevê sempre "negativo" acerta em 970 dos 1000 casos – mas falha em todos os positivos. Do ponto de vista médico ou de engenharia, esse modelo é **inútil**.

A proporção de casos raros é medida pelo IR. Quanto mais baixo for o IR, mais difícil é o problema. O algoritmo standard falha em dois pontos:

1. **Splits enviesados** – o critério de Gini favorece divisões que isolam a classe majoritária, ignorando a minoritária
2. **Folhas enviesadas** – as probabilidades emitidas pelas folhas estão sistematicamente abaixo de 0.5, pelo que o modelo nunca prevê a classe rara



OS DADOS DO ESTUDO




Escala e Diversidade

Utilização de 38 datasets binários provenientes de domínios variados, incluindo análises médicas, defeitos de software e dados ambientais.




Nível de Dificuldade

Os datasets selecionados apresentam níveis de desequilíbrio desafiantes, com Imbalance Ratios (IR) a oscilar entre ~ 0.05 e ~ 0.24 .



Processo de Descoberta

Implementação de um sistema de descoberta e importação automática dos datasets, garantindo reprodutibilidade e escalabilidade.



Controlo de Qualidade

Filtro onde datasets com menos de 20 instâncias da classe minoritária foram excluídos, assegurando robustez estatística na validação cruzada.

O CAMINHO

Fase 1

Fase 1

Baseline

Gini Standard, sem qualquer modificação estrutural ou métrica.

Fase 2A

Weighted CART

Implementação de pesos para balancear splits e folhas


Fase 2B

Reduced Error Pruning

Poda bottom-up por G-Mean. Actua como controlo experimental estrutural.

Fase 2C

Cost-Sensitive Tree
Aplicação de custos assimétricos. O produto final otimizado.



ANÁLISE DAS MODIFICAÇÕES INDEPENDENTES

FASE 2A: WEIGHTED CART

- Aborda o problema tratando o desequilíbrio numa perspetiva de proporções estatísticas. (Ting, 2002)
- Aplica pesos específicos que re-balanceiam o impacto de cada amostra durante os splits e nos cálculos das folhas:

$$w_i = \frac{n}{2ny_i}$$


FASE 2B: REDUCED ERROR PRUNING

- Serve fundamentalmente como nosso controlo experimental.
- Utiliza uma técnica de poda bottom-up orientada pela métrica G-Mean (adaptação de Quinlan, 1987). Por não alterar o critério de split nem as folhas, permite isolar e testar se o problema primário reside apenas na estrutura da árvore.

Fase 2A



Fase 2B



O PRODUTO FINAL

Cost-Sensitive Tree - Fase 2C

Enquanto o Weighted CART melhora o desempenho ajustando proporções, a Cost-Sensitive Tree vai mais longe: enquadra o desafio como um problema de custos assimétricos.

Em contextos do mundo real (detecção de falhas de software ou doenças), perder um caso positivo (Falso Negativo) custa exponencialmente mais do que gerar um falso alarme (Falso Positivo).

A nossa árvore incorpora esta assimetria de custo diretamente no critério matemático de split, garantindo que o algoritmo penaliza severamente os erros mais críticos para o negócio.



O LIMIAR DE BAYES ÓTIMO

0.167

Limiar de Decisão (τ^*)


Em vez de procurar o melhor limiar através de tentativa e erro (tuning de hiperparâmetros), utilizamos o limiar de Bayes ótimo derivado teoricamente da função de custo (Elkan, 2001).

Assumindo um Falso Negativo 5x mais penalizador:


$C(\text{FN})=5$, $C(\text{FP})=1$.


$$\tau^* = C(\text{FP})C(\text{FN}) + C(\text{FP}) = 15 + 1 \approx 0.167$$

Fase 2C



RESULTADOS FINAIS





O PROBLEMA DO DESEQUILÍBRIO DE CLASSES

TRABALHO PRÁTICO –
APRENDIZAGEM COMPUTACIONAL I

Grupo 5: Afonso Marcos, Artur Anselmo,
Marcos Torres